

犀牛鸟开源 - 实战任务

混元大语言模型项目

本次共设置两个实战任务，参与者选择其中一个完成。

【提交方式】

本次实战任务由参与者自行创建并维护开源项目仓库，无需向 Hy3 官方仓库提交 Pull Request。

- 在 GitHub 等平台自行新建公开仓库，完成后提交仓库链接
- README 需写明项目介绍、运行方式与环境要求
- 不得将 API Key 等密钥硬编码或提交进仓库，需通过环境变量或配置文件传入
- 项目命名与 README 中需标注为个人 / 活动作品，避免被误认为腾讯官方发布
- 模型能力调用通过 Hy3 完成，不需要训练或微调模型

1. 【犀牛鸟实战任务】开放式场景：AI 应用与评判标准设计

Hy3 application with custom evaluation criteria for open-ended tasks

【任务描述】

基于 Hy3 构建一个面向真实用户场景的 AI 应用，该场景的输出不存在唯一标准答案。参与者需自行定义该场景下的评判标准，设计并实现一套完整的评估方法，并通过实验验证该评估方法的有效性。

【完成方式】

参与者从下列应用方向中选择一个，也可自拟：

- 法律：合同审阅、法规问答、案件检索与归纳
- 医疗：病历摘要、用药咨询（科普层面，避免临床决策）、医学文献综述
- 学术：论文阅读助手、文献综述生成、引用核对
- 金融分析：财报阅读、行业研报摘要、公开数据问答
- 内容生产：文案改写、多语种本地化、结构化报告生成
- 复合型产物评估：调研报告、方案文档等由多步流程产出内容的质量评估

应用侧

基于 Hy3 构建一个可运行的 AI 应用，面向明确的真实用户场景，而非仅在通用 benchmark 上做能力展示。

需说明目标用户、待解决的问题，以及该场景引入大模型的必要性。

评估方法设计

自定义一套面向该场景的评估方法，建议覆盖 5 个以上关键评估维度，例如事实准确性、证据可追溯性、专业术语正确性、安全合规性、用户可理解性、格式规范性等。

每个维度需给出可操作的判定标准，即不同评审者依据该标准应能得出接近的结论。应避免使用「较好地满足要求」「基本符合」等缺少判定依据的表述。

实现自动或半自动的评测流程，实现方式不限，rubric 打分、规则校验、LLM-as-judge、沙盒执行、多 Agent 交叉验证、人工标注接口等均可，并说明选择该方式的设计依据。

评测样本

评测样本由参与者自行收集或构造，需说明样本来源、构造方式与覆盖范围。

样本集需包含一定比例的难例与反例，不应只保留容易得分的样本。

评估方法的有效性验证

需通过实验说明所设计的评估方法是可靠的，至少完成以下两项：

- 判别力验证：构造质量存在明显差异的输出（如好、中、差三档），验证评估方法能否正确区分并排序
- 一致性验证：验证评估结果与人工标注的一致程度，或同一份输出多次评估的分数波动情况

鼓励额外完成对抗性验证，例如输出的结果预期通过增加篇幅、堆砌专业术语、伪造引用等方式来获取高分，这种情况下检验评估方法是否能够有效区分。

评测执行

在自构建的评测样本集上完成一次完整评测，输出结果表格与典型 case 归因分析。

【产出】

- 开源项目仓库：应用源码、README、环境配置样例与运行说明
- 评测材料：评测样本集、评估方法说明文档、评测脚本、完整结果表格
- 有效性验证结果：评估的实验过程与数据
- 分析报告：场景选择理由、AI 应用的解决方案、评估维度设计依据、评测结论、模型失败模式归纳与能力边界分析、实际评测中挖掘到的一些典型模式
- 时长 2 分钟以内的 demo 视频或 GIF

【参考链接】

Hy3 仓库：<https://github.com/Tencent-Hunyuan/Hy3>

2. 【犀牛鸟实战任务】可验证场景：过程评估与错误定位

Hy3 application with process-level evaluation and error localization

【任务描述】

基于 Hy3 构建一个面向可验证场景的 AI 应用，场景领域需存在标准答案，如科学学科、算法竞赛、代码功能等。在此基础上设计一套面向可验证场景的过程评估方法：除判断最终答案的正确性外，还需评估推理过程是否成立、定位错误发生的步骤、归纳错误类型，并识别最终答案正确但推理过程无法支撑该结论的样本。

【完成方式】

参与者从下列方向中选择一个，也可自拟：

- 数学：竞赛题、高等数学、应用题，评估推导链条的完整性与正确性
- 物理：力学、电磁学等计算题，评估建模假设、公式选用、单位与量纲
- 算法竞赛：给定题目与测试数据，评估解法思路、复杂度分析与边界处理
- 代码任务：给定需求与测试用例，评估实现逻辑的正确性，而非仅判断测试是否通过

应用侧

基于 Hy3 构建一个可运行的应用，能够针对该领域的题目/任务产出完整的解答过程，而非仅输出最终答案。

评测题集

构建评测题集，每道题需具备明确的标准答案与可自动校验的判定方式。

题目需按难度分层，覆盖从基础到高难度的区间，并说明题目来源、构造方式与分层依据。

过程评估设计

设计一套评估解题过程的方法，至少实现以下能力：

- 过程正确性判定：判断推理链条是否成立，是否存在跳步、循环论证、误用定理、条件遗漏、幻觉等问题
- 错误步骤定位：当解答错误时，定位错误开始出现的步骤
- 错误类型归类：建立错误分类体系，例如题意误读、概念理解错误、计算错误、条件遗漏、跳步推导、格式不符等
- 结果正确但过程不成立的样本识别：例如猜中选项、数值巧合、误用定理却得出正确结果、恰好通过测试用例但实现逻辑存在缺陷等情况

实现方式不限，规则校验、分步 LLM 审查、沙盒执行验证、多 Agent 交叉复核等均可。

过程评估器的有效性验证

需利用标准答案验证所设计的过程评估器是否可靠，至少完成以下两项：

- 定位准确率：在答案错误的样本上，评估器能否判定过程存在问题，并定位到实际出错的步骤
- 误报率：在答案正确的样本上，被评估器判定为过程存在问题的样本，经人工抽检确认其中属于真实问题与属于误报的比例

结果分析

输出完整评测结果，包含最终答案准确率、过程正确率，以及错误类型分布。

按难度分层进行分析，指出模型表现开始明显下降的难度区间。

【产出】

- 开源项目仓库：应用源码、过程评估模块、README、环境配置样例与运行说明
- 评测材料：分层题集及标准答案、答案校验脚本、过程评估脚本
- 完整结果：最终答案准确率、过程正确率、错误类型分布、难度分层结果
- 有效性验证结果：定位准确率与误报率的验证数据及人工抽检记录
- 分析报告：过程评估方法设计依据、错误分类体系说明、典型案例分析、模型能力边界与临界点分析
- 时长 2 分钟以内的 demo 视频或 GIF，展示一次完整的解题与过程评估流程

【参考链接】

Hy3 仓库：<https://github.com/Tencent-Hunyuan/Hy3>